



Community detection для улучшения товарных эмбедингов

Community detection for improving product embeddings

Индивидуальный проект | Исследовательский проект

Докладчик

Делекторский Богдан, БКНАД 242

Студент

Руководитель **Иванчиков Борис Алексеевич**

ML разработчик · инженер, Яндекс

Предметная область: матчинг товаров

В каталоге один товар может быть представлен множеством предложений с разными названиями, описаниями и характеристиками

Задача матчинга: автоматически находить предложения, относящиеся к одному товару. Для этого текст каждой карточки преобразуется моделью в векторное представление - embedding

Качественные embeddings располагают похожие товары близко друг к другу, а разные - далеко. Это позволяет находить одинаковые товары, даже если их описания различаются





Актуальность работы

1

Качество каталога

Одинаковые товары могут быть разделены между разными карточками, из-за чего каталог становится менее целостным

2

Поиск и рекомендации

Embeddings используются для поиска похожих товаров и формирования кандидатов в рекомендательных системах

3

Масштаб и вариативность

В исходном датасете около 4,8 млн записей; названия и характеристики одного товара могут различаться

4

Обучение без разметки

Размеченные пары одинаковых товаров ограничены, поэтому важно использовать сигнал, содержащийся в самих данных



Цель и задачи работы

Цель

Исследовать товарные эмбединги и оценить влияние дообучения по сообществам на их качество

Задачи

- 1 Проанализировать исходные embeddings
- 2 Изучить и адаптировать DeepCluster
- 3 Сравнить KMeans и HDBSCAN
- 4 Получить псевдометки кластеров
- 5 Дообучить ruBERT-tiny2 по псевдометкам
- 6 Оценить embeddings по KNN-метрикам



Исходные данные и модель

Исходный датасет

источник	датасет электроники Яндекс Маркета
объём	около 4,8 млн товарных записей
категории	122 товарные категории
текст	поле <code>model_text</code> с полным описанием карточки товара
вектор	embedding размерности 312

Модель и эксперимент

Модель: ruBERT-tiny2

Представление товара: CLS-вектор размерности 312

Для DeepCluster сформирована сбалансированная выборка из 20 категорий: по 1 250 товаров в каждой

20 000

товаров для обучения

5 000

товаров для validation




Поиск сообществ: KMeans и HDBSCAN

Критерий	KMeans	HDBSCAN	Значение для DeepCluster
Принцип	Делит объекты на K групп вокруг центроидов	Ищет группы объектов высокой плотности	Кластеры становятся временными классами
Число кластеров	Задается заранее	Определяется автоматически	Можно контролировать число псевдометок
Метка для товара	Есть у каждого объекта	Часть объектов может быть шумом	Нужна метка для каждого товара
Результат в работе	Выбран $K = 100$	62,805% товаров отнесены к шуму	Используется вся train-выборка
Итог	Подходит для DeepCluster	Не выбран для итогового обучения	Псевдометка = номер кластера товара

Выбор числа кластеров KMeans

Качество KMeans при разных K



Результат выбора

K = 100

итоговая конфигурация

Проверенные значения:

5 · 10 · 20 · 50 · 100

При K = 100:

Silhouette - 0,065

ARI - 0,238

NMI - 0,511

DeepCluster: идея метода


Метод основан на статье Caron et al., *Deep Clustering for Unsupervised Learning of Visual Features*, 2018



Адаптация DeepCluster к товарным текстам

DeepCluster в статье

- изображения
- CNN-encoder
- visual features
- KMeans-кластеризация
- псевдометки: номера кластеров




DeepCluster для товаров

- тексты `model_text`
- `ruBERT-tiny2`
- CLS-векторы размерности 312
- KMeans-кластеризация
- псевдометки: номера кластеров


Основная идея DeepCluster сохранена: изменены тип данных и encoder

Постановка итогового эксперимента



Динамика обучения DeepCluster

Динамика loss в итерациях DeepCluster



После каждого пересчета кластеров loss снова растет: псевдометки меняются. Внутри каждой итерации loss устойчиво снижается. К последней итерации encoder лучше предсказывает псевдометки кластеров.

Результат обучения

4,7 → 0,12


Cross-entropy loss

- 3 итераций DeepCluster
- Псевдометки пересчитываются
- Loss снижается внутри итераций

Результат: KNN-оценка embeddings

Accuracy

0,855 → **0,839**
бейзлайн после DeepCluster



Macro-F1

0,853 → **0,836**
бейзлайн после DeepCluster



На независимой validation-выборке **KNN-метрики немного снизились** по сравнению с исходными embeddings. **DeepCluster успешно минимизирует loss** по псевдометкам, однако в проверенной конфигурации не улучшает разделение товарных категорий в embedding-пространстве.

Интерпретация результатов

1 Структура пространства

Кластеризация выделяет сообщества близких товаров в исходных embeddings

2 DeepCluster обучился

Loss по псевдометкам снизился с 4,7 до 0,12

3 Внешняя метрика

KNN по категориям немного снизился, поэтому настройки метода требуют дальнейшей проверки

DeepCluster подтвердил возможность использовать структуру embedding-пространства как сигнал обучения. Однако улучшение матчинга требует подбора параметров и проверки на размеченных товарных парах.

Ограничения эксперимента

- 1 Косвенная метрика**

KNN по категориям оценивает структуру embeddings, но не измеряет matching напрямую
- 2 Одна конфигурация**

Проверена одна конфигурация: $K = 100$, три итерации и один набор параметров обучения
- 3 Ограниченные ресурсы**

Локальный Mac не позволяет многократно пересчитывать embeddings и дообучать encoder на миллионах товаров
- 4 Проверка матчинга**

Категория не определяет конкретный товар. Для прямой оценки нужны размеченные пары одинаковых и разных товарных карточек



Дальнейшие шаги

- 1 Подобрать параметры** Добиться не только снижения внутреннего loss, но и улучшения внешней метрики
- 2 Оценить matching напрямую** Использовать размеченные пары карточек и метрики Recall@K, Precision@K и F1
- 3 Увеличить масштаб** Запустить обучение на большей выборке, **используя вычислительные ресурсы**
- 4 Сравнить подходы** Реализовать другие методы дообучения embeddings и сравнить их результаты с DeepCluster



Основные результаты и выводы

Проанализированы данные и embeddings

Исследованы товарные тексты, категории и структура пространства эмбеддингов

Выбран KMeans

Метод назначает псевдометку каждому товару и подходит для DeepCluster

Адаптирован DeepCluster

Метод адаптирован для текстов товаров на базе ruBERT-tiny2

Проведено дообучение

Выполнены три итерации:
embeddings → KMeans → псевдометки → обучение

Внутренний loss снижен

Cross-entropy уменьшился с 4,7 до 0,12

Внешняя метрика не улучшилась

KNN по категориям снизился, поэтому нужны подбор параметров и проверка matching на размеченных парах

Список использованных источников

Базовые работы

Caron M. et al. *Deep Clustering for Unsupervised Learning of Visual Features*. ECCV, 2018.

Devlin J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL, 2019.

cointegrated/rubert-tiny2. Model card на Hugging Face.

McInnes L., Healy J., Astels S. *hdbscan: Hierarchical Density Based Clustering*. JOSS, 2017.

Датасет электроники Яндекс Маркета и предвычисленные embeddings

Предоставлены руководителем проекта для проведения исследования и DeepCluster-эксперимента



Спасибо за внимание!

Community detection для улучшения товарных эмбеддингов

Докладчик Делекторский Богдан, БКНАД 242

Репозиторий github.com/BogdanDelektorskiy/Course_work_community_detection

Ссылка на статью arxiv.org/pdf/1807.05520

